Idea 1: qué dicen los datos

Proteína de arveja para la industria de ingredientes. Reporte del análisis exploratorio hecho el 30/10/2026, antes del evento. No se entrenó ningún modelo (regla del hackathon): son medias por grupo, descomposiciones descriptivas, correlaciones exploratorias y mapas.

En una línea

Los datos son buenos para estimar la proteína esperada por tipo, variedad y región, con el nivel calibrado contra lo que llega a los silos. La parte difícil es que el clima de la campaña mejore mucho esa estimación: las señales existen pero son débiles y están mezcladas con el año. El pitch tiene que vender una probabilidad calibrada y honesta que se actualiza, no una predicción exacta.

Los datos

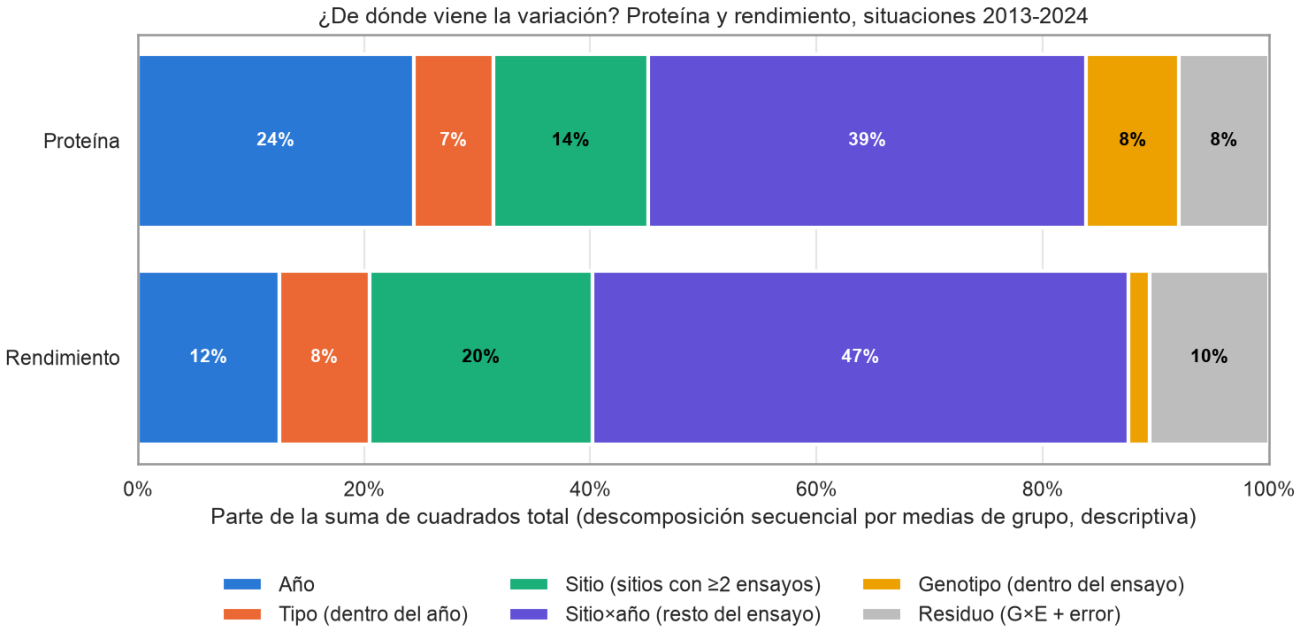
Dataset	Tipo	Rango	Para qué
Pea_dataset (INRAE, Terres Inovia, GEVES)	Tabular: 4.450 situaciones sitio × variedad × año, 3.326 con proteína	2013-2024 (+2003-04)	Etiquetas: proteína (% MS) y rendimiento; suelo, tipo, clase de variedad, siembra
SAFRAN / SIM2 (Météo-France)	Serie de tiempo diaria, grilla de 8 km	1958 hasta ayer	Clima por fase para entrenar, escenarios, campaña en vivo
Agreste SAA	Panel anual por departamento	2010-2025	Rendimiento real de chacra
RPG (parcelas PAC)	Vectorial, agregado por departamento	2015-2024	Dónde hay arveja y cuánta es de invierno
Encuestas de calidad Terres Univia	Tabla chica (PDF)	2015-2025	Calibrar la proteína contra los silos (11 valores nacionales, 35 por cuenca)
Imágenes	No hay		Las parcelas de ensayo miden ~10 m²: no sirven para satélite

Ojo con el tamaño real: dentro de un mismo ensayo la proteína varía poco, así que la unidad de información es el ensayo (sitio × año × tipo). Hay **~250 ensayos con proteína en 12 años**, no 3.326 filas independientes.

Los 12 hallazgos

1. El ambiente manda

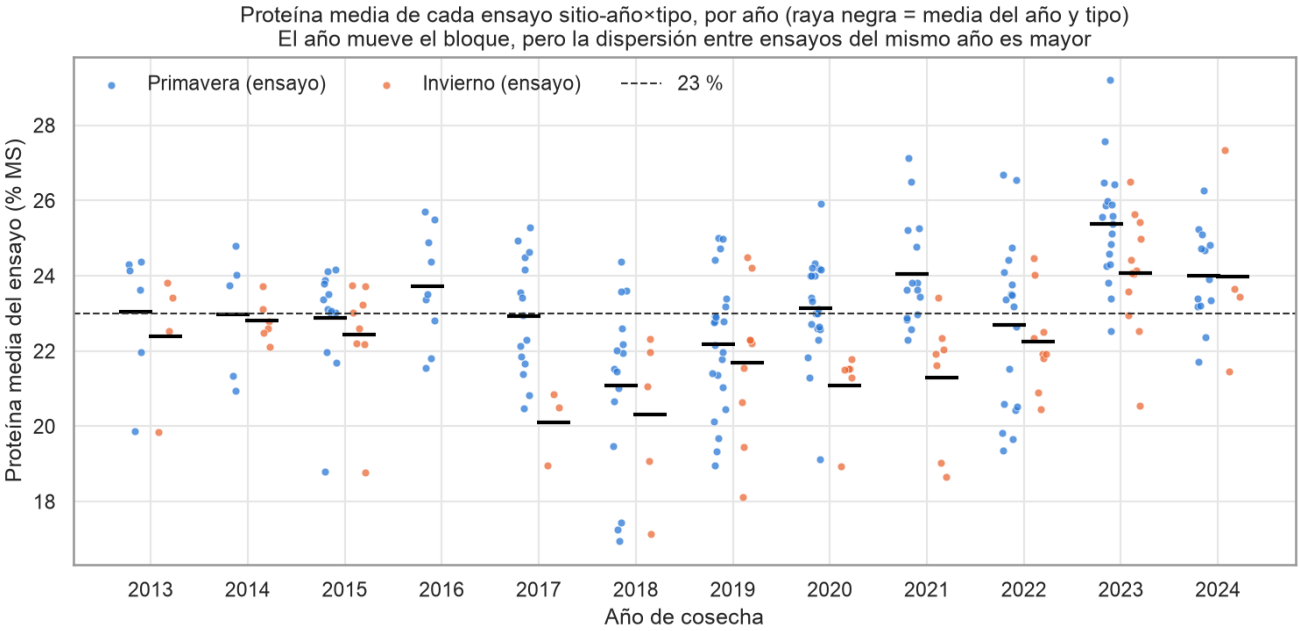
Del total de variación de la proteína, ~84 % es ambiente (año 24 %, tipo 7 %, sitio 14 %, sitio × año 39 %) y solo 8 % es la variedad dentro del ensayo. En rendimiento, ~88 % es ambiente.



Descomposición descriptiva de la variación de proteína y rendimiento. (pea/05_descomposicion_varianza.png)

2. El año solo no alcanza

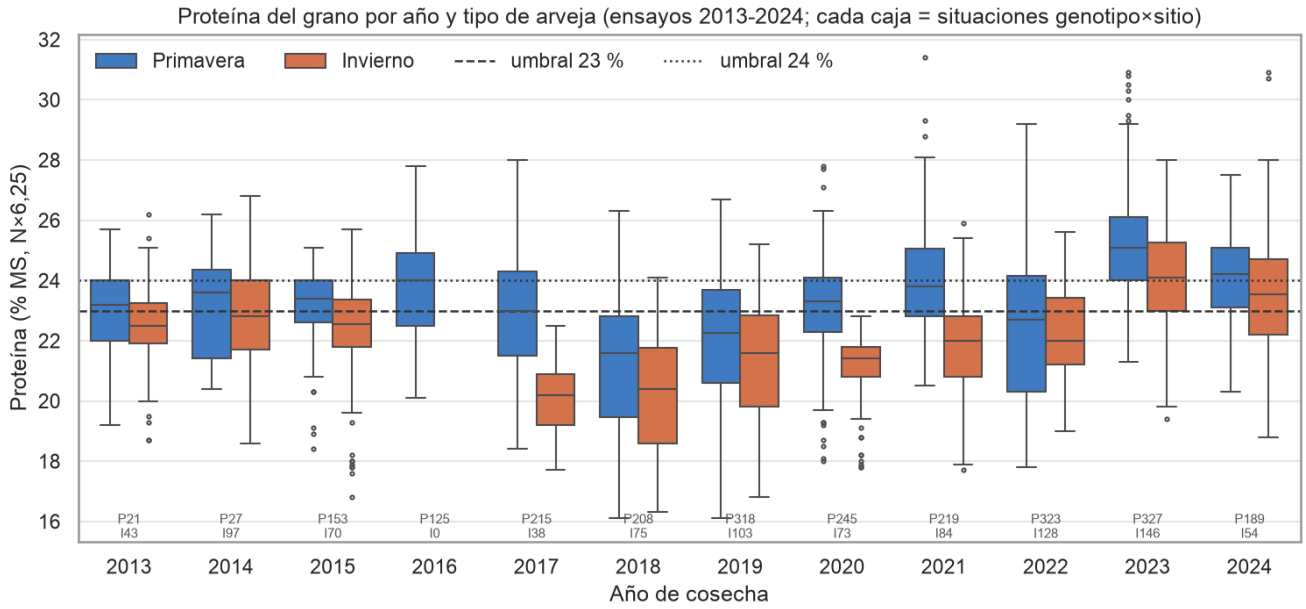
Las medias anuales van de 20,9 % (2018) a 24,9 % (2023), pero dentro de un mismo año los ensayos se dispersan con un desvío de 1,7 puntos. Lo que el clima tiene que explicar es el sitio × año.



Proteína media de cada ensayo, por año. (pea/15_ensayos_por_anio.png)

3. El umbral de 23 % depende mucho del año y del tipo

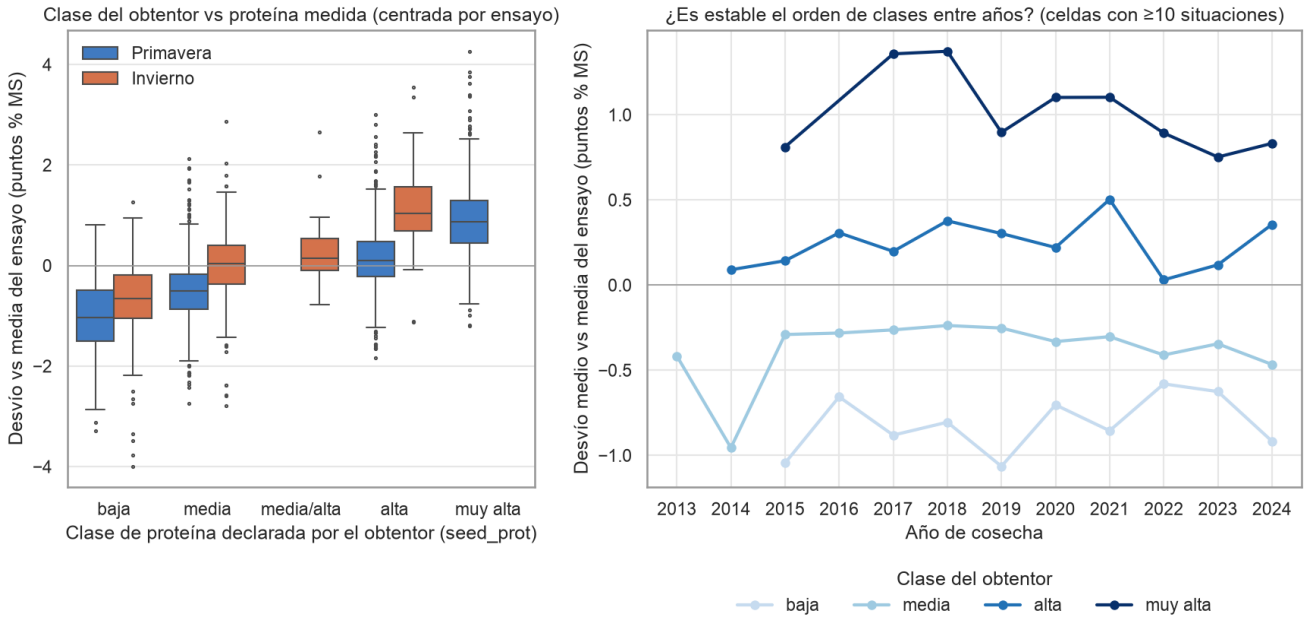
Lo supera el 51 % de los ensayos: 15 % en 2018 y 87 % en 2023. Primavera 59 %, invierno 34 %.



Proteína por año y tipo, con las líneas de 23 % y 24 %. (pea/01_proteina_por_anio_tipo.png)

4. La variedad es un corrimiento estable, y la clase del obtentor lo captura

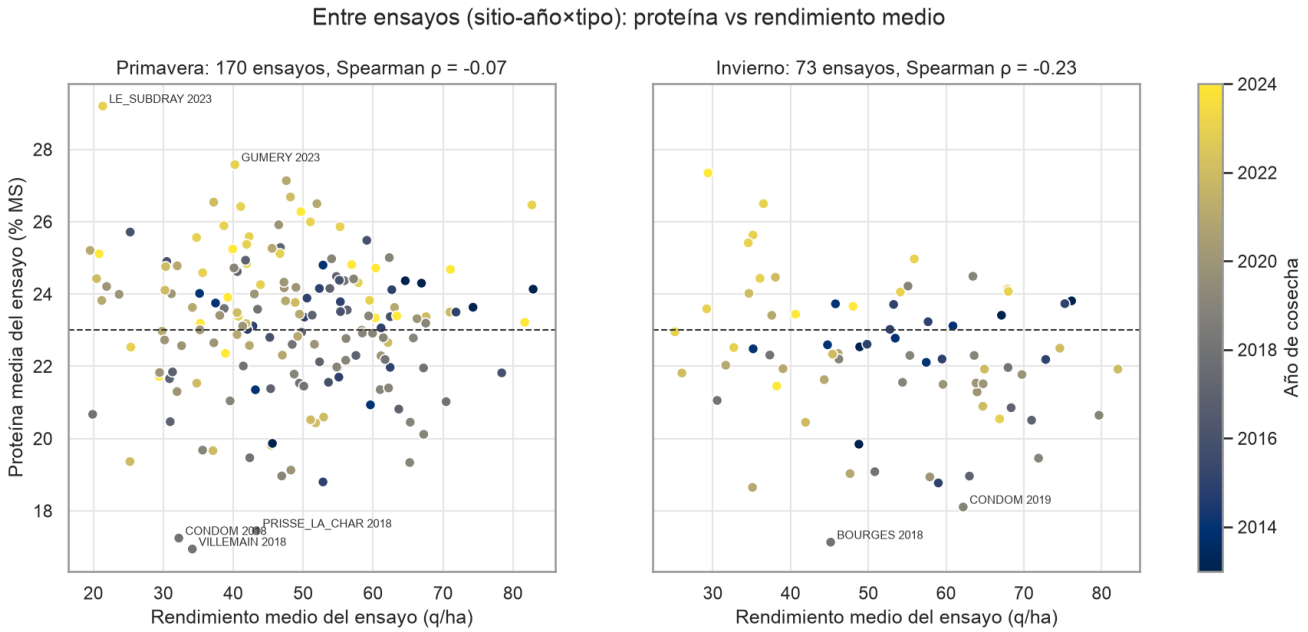
Respecto de la media del ensayo: clase baja −0,8, media −0,3, alta +0,3, muy alta +0,9 puntos, todos los años. Pero depende del tipo: "alta" vale +1,1 en invierno y +0,1 en primavera.



Clase de proteína declarada por el obtentor vs proteína medida. (pea/08_clase_obtentor_vs_proteina.png)

5. Proteína y rendimiento casi no se relacionan

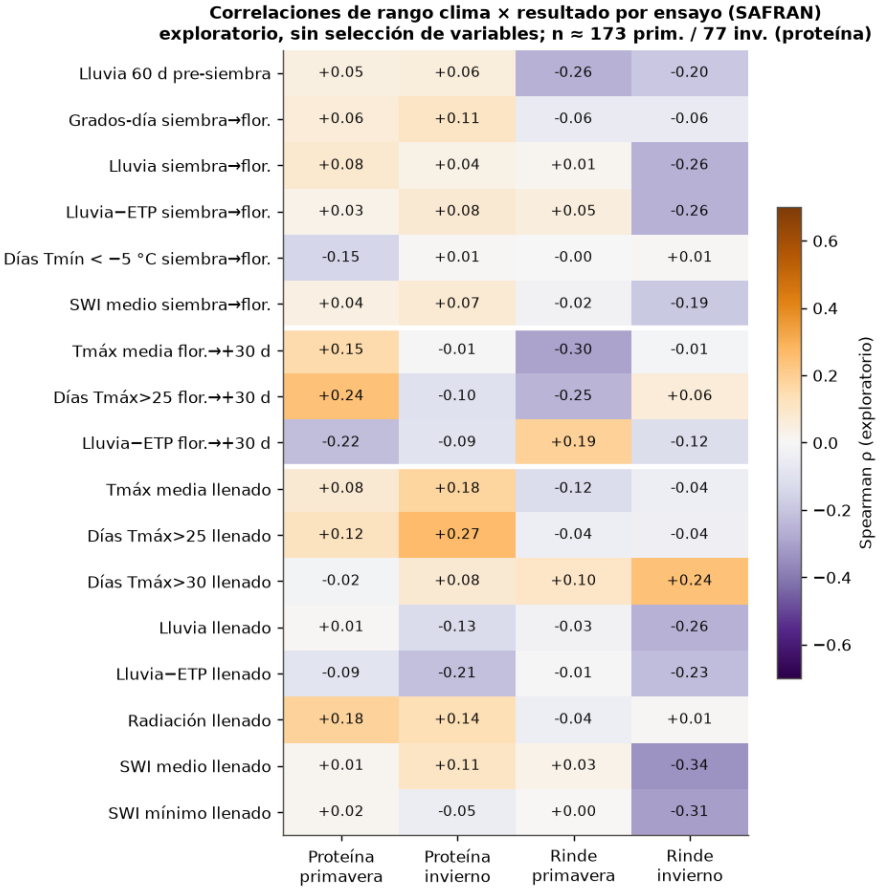
Entre ensayos, ρ −0,07 en primavera y −0,23 en invierno. La proteína muy alta suele ser estrés (LE_SUBDRAY 2023: 29 % con 21 q/ha). Hay que predecir las dos cosas.



Media de proteína vs media de rendimiento de cada ensayo. (pea/03_ensayo_proteina_vs_rendimiento.png)

6. Las señales del clima son débiles

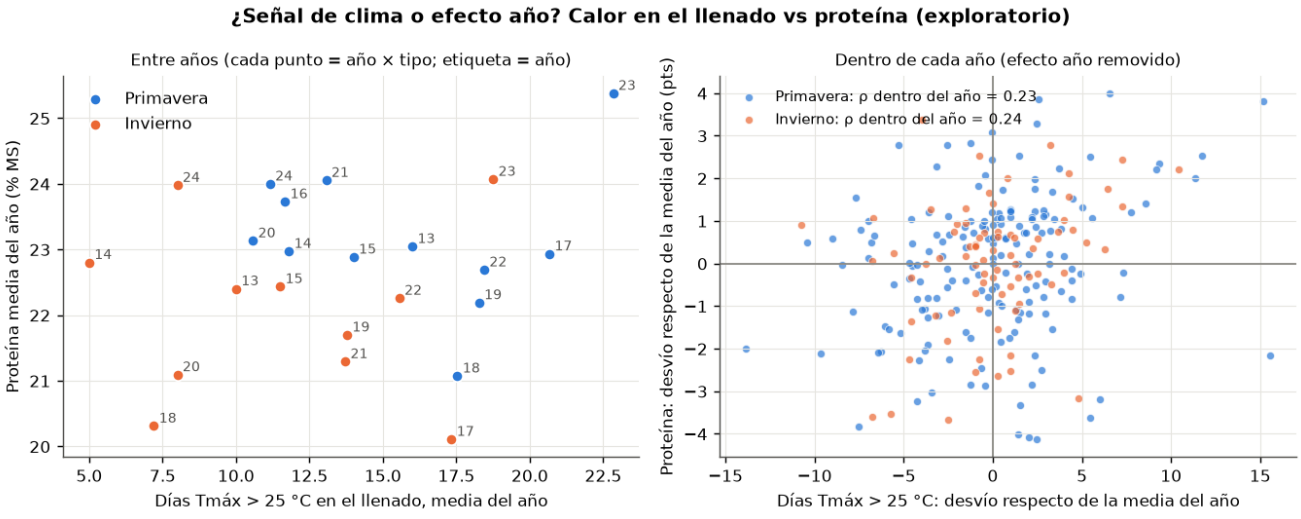
Ninguna de las 17 variables de clima por fase pasa de |ρ| 0,27 con la proteína. Y el calor en el llenado va con más proteína, no menos. La lluvia total de la campaña no dice nada: la señal está en la fase.



Correlaciones exploratorias clima × resultado (SAFRAN), sin selección de variables. (clima/08_mapa_correlaciones_exploratorio.png)

7. El clima está mezclado con el año

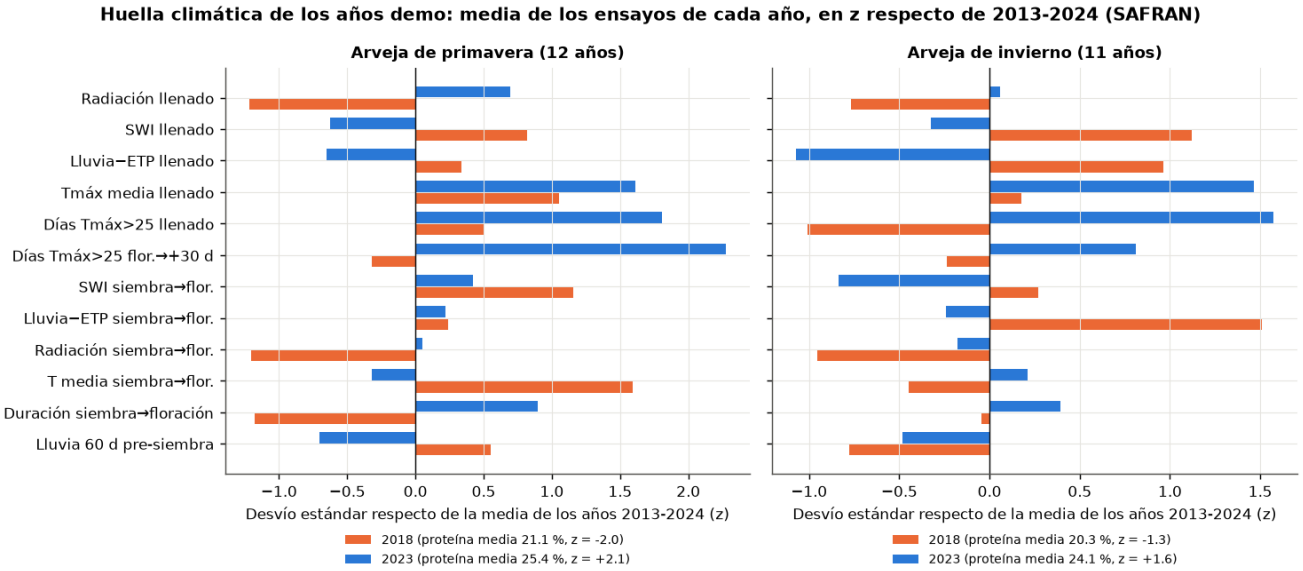
En primavera, calor vs proteína da ρ −0,31 entre medias anuales pero +0,23 dentro de cada año. Con 12 años, una variable que separe 2018 de 2023 puede parecer importante sin serlo.



La misma relación vista entre años y dentro de cada año. (clima/09_confusion_con_anio.png)

8. 2018 vs 2023: lo que los separa no es el calor

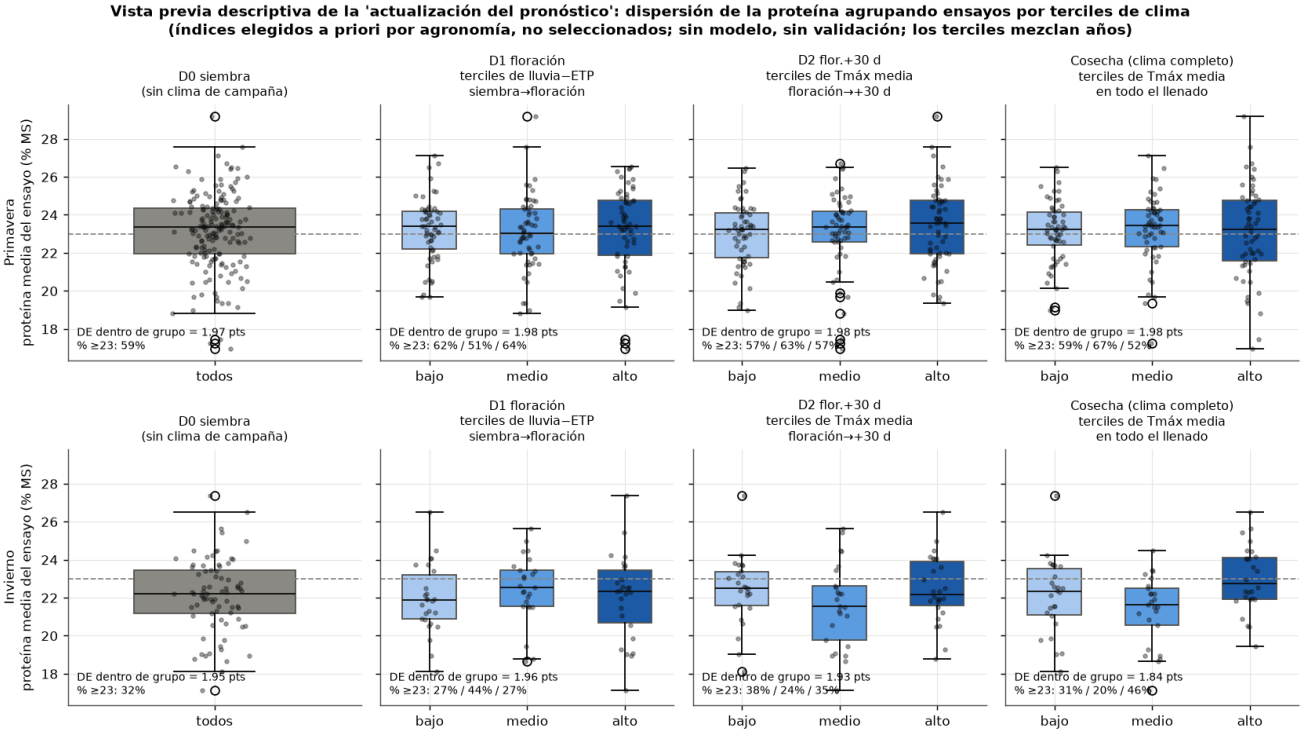
Los dos tuvieron llenados muy calientes. 2018 fue sembrado tarde, oscuro y con suelos húmedos; 2023 tuvo el llenado más seco en 44 años en Eure-et-Loir y Aisne.



Huella climática de los dos años de la demo, en desvíos respecto de 2013-2024. (clima/15_huella_climatica_2018_vs_2023.png)

9. La incertidumbre no se achica sola

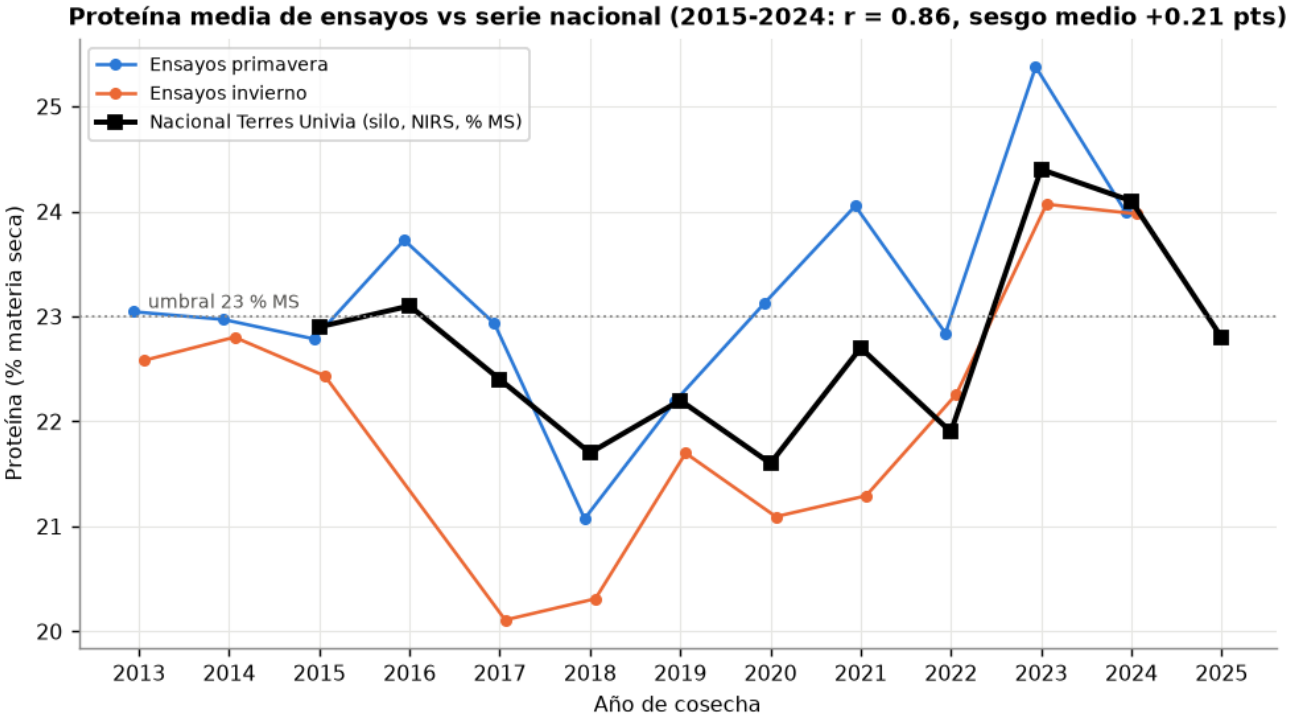
En la fecha "floración + 30 días" todavía falta ver 64-80 % del calor del llenado, y agrupar por un solo índice no achica la dispersión. Por eso el valor tiene que estar en la calibración, no en la precisión.



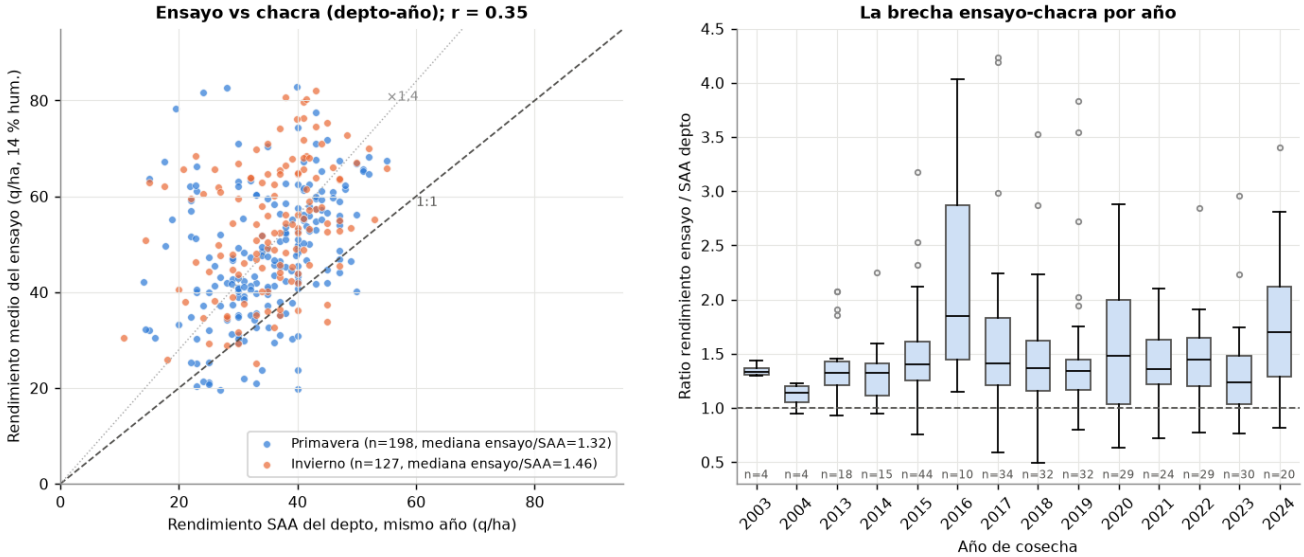
Dispersión de la proteína agrupando ensayos por terciles de clima en cada fecha de decisión. (clima/11_actualizacion_por_terciles.png)

10. La proteína de ensayo generaliza a la chacra; el rendimiento no

Proteína: r 0,86 contra la serie nacional de silos (sesgo +0,2 puntos). Rendimiento: el ensayo rinde 1,36 veces la chacra y la correlación con el departamento es solo 0,35. El rendimiento va siempre relativo.



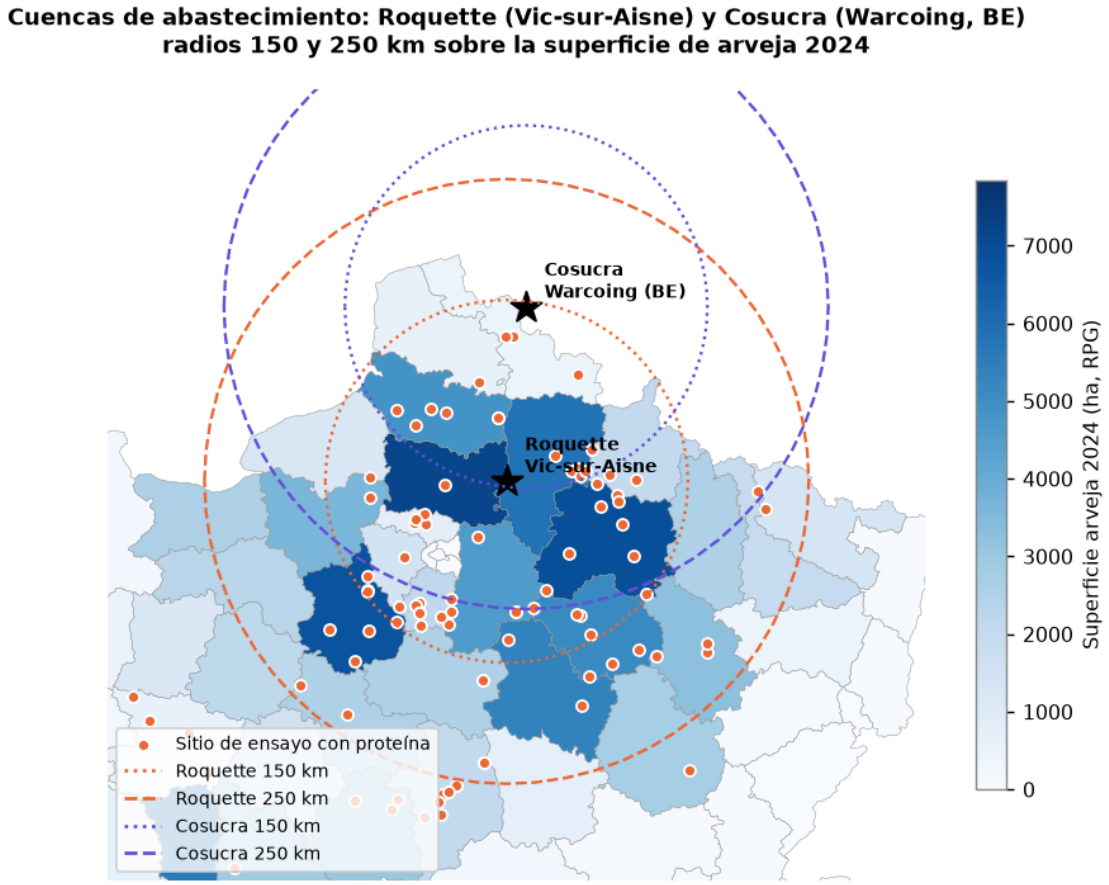
Proteína media de los ensayos vs serie nacional Terres Univia. (contexto/07_proteina_ensayos_vs_nacional.png)



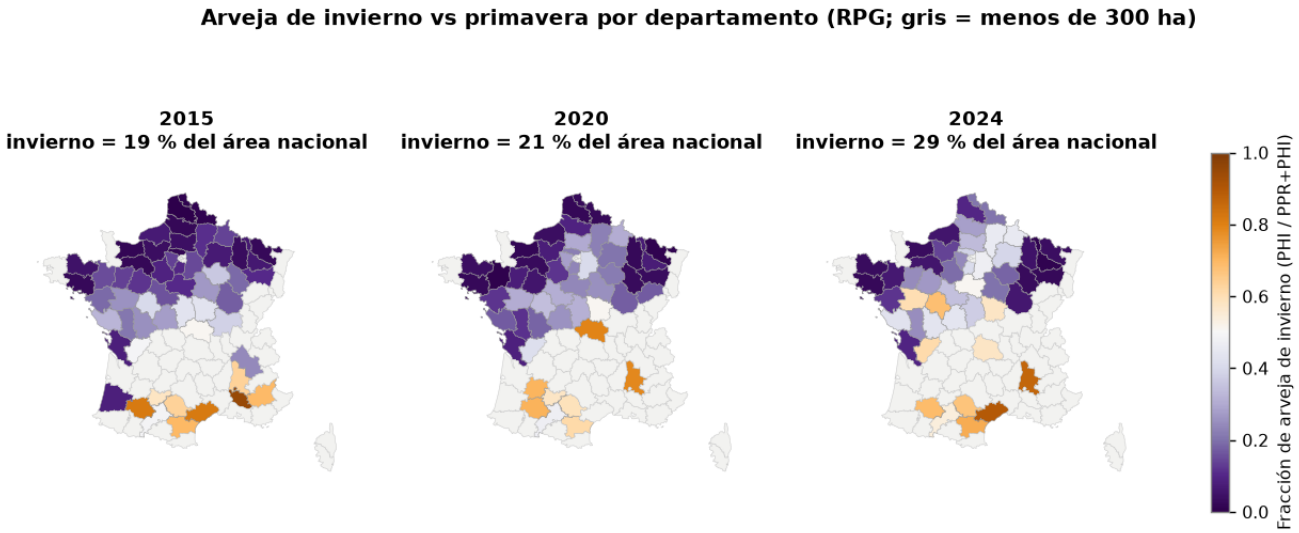
Rendimiento de ensayo vs rendimiento del departamento (SAA). (contexto/06_brecha_ensayo_chacra.png)

11. La cuenca de Roquette es el lugar para la demo

A ≤250 km de Vic-sur-Aisne está el 64 % del área francesa de arveja, y el 89 % de esa área tiene ensayos. Ahí crece la arveja de invierno (Aisne 11 % → 46 % entre 2015 y 2024), que da ~1 punto menos de proteína. Hueco: Oise, 2.° departamento del país, tiene 1 solo ensayo con proteína.



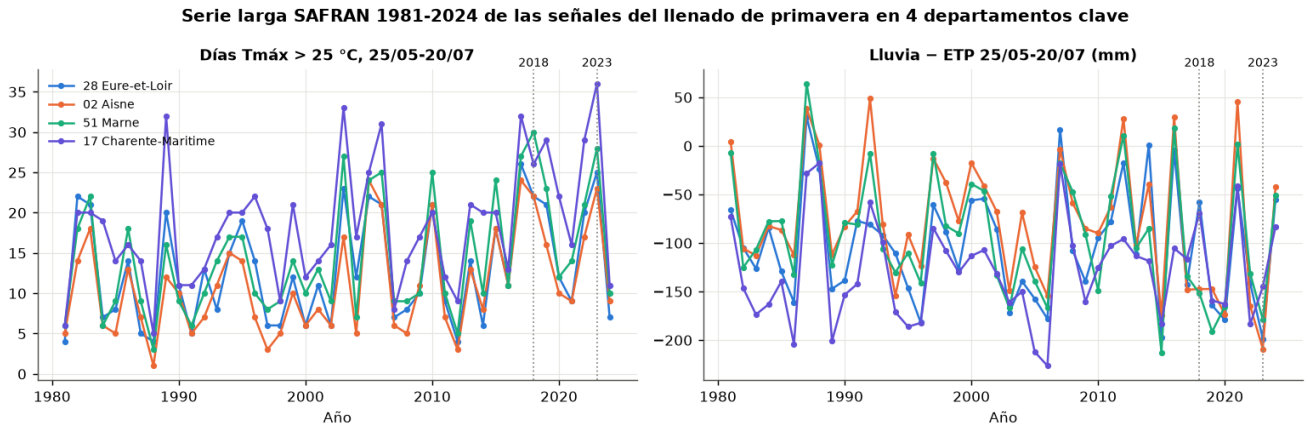
Cuencas de Roquette y Cosucra sobre la superficie de arveja 2024, con los sitios de ensayo. (contexto/10_mapa_cuenca_roquette_cosucra.png)



Fracción de arveja de invierno por departamento (RPG). (contexto/02_mapa_fraccion_invierno_rpg.png)

12. 2023 está en el borde de la climatología

Los días de calor en el llenado suben +1,2 a +2,2 por década (Marne: 11,6 → 17,3 días entre 1981-2000 y 2005-2024). Los escenarios tienen que pesar más los años recientes.



Serie larga 1981-2024 de los índices de llenado en departamentos clave. (clima/14_serie_larga_llenado.png)

Cómo se cruzan los datos

1. Limpiar el Pea_dataset: corregir 5 coordenadas (AVANCON, GRIGNON, DIOU, GRIGNON_INRAE, ANGERS_JAILLIERE) y la fecha de cosecha de LE_RHEU 2013. No sacar los outliers de 2018: son señal.
2. Asignar a cada ensayo la celda SAFRAN más cercana (todas a ≤5,1 km).
3. Calcular el clima por fase, anclado en la floración y con largos fijos (siembra → floración, floración → +30 d, +30 → +55 d). Nunca anclar en la cosecha real. Usar SAFRAN siempre.
4. Tabla por ensayo: media de proteína y rendimiento relativo + clima por fase + suelo + tipo + región + fecha de siembra.
5. Tabla por variedad: desvío respecto de la media del ensayo + clase del obtentor × tipo.
6. Pasar a la cuenca del comprador: clima SAFRAN por departamento, ponderado por área RPG × fracción de invierno.
7. Rendimiento de chacra = rendimiento medio SAA del departamento × índice relativo predicho.
8. Calibrar el nivel de proteína contra la serie nacional y las 35 medias por cuenca, sin tocar el año de test.

Qué hay que entrenar en el evento

Componente	Qué predice	Cómo
Modelo ambiental (el núcleo)	Proteína media del ensayo y rendimiento relativo	Ridge o GBM chico, 10 a 20 variables (~250 ensayos). Uno por fecha de decisión: siembra, floración, floración + 30 d
Corrimiento de variedad	Desvío de la variedad dentro del ensayo	Tabla de medias por clase del obtentor × tipo (no hace falta ML)
Incertidumbre	Distribución de la proteína y P(≥23 %)	Regresión por cuantiles o conformal agrupado por año, recalibración isotónica
Escenarios	El clima que falta después de la fecha de corte	Ensamble con lo observado hasta hoy + cada año de SAFRAN 1995-2024 desde hoy, sin el año de test
Cuenca (opcional)	Toneladas de proteína en la cuenca	Monte Carlo con RPG y SAA

Baselines a mostrar: B0, tasa ≥23 % por tipo × macro-región; B1, B0 + corrimiento por clase del obtentor; y el "oráculo del año" (la media real del año), que muestra cuánto queda en sitio × año.

Validación: dejando un año afuera (12 folds), nunca mezclando filas. Métricas por año: Brier, curva de confiabilidad, cobertura de intervalos, error en puntos de proteína.

Regla de corte: a la hora 10, el modelo con clima tiene que bajar el Brier de B0 al menos 10 % y ganarle a B1 en 7 de 12 años. Si no, se presenta el atlas calibrado (B1 + escenarios) y se dice claramente que el clima no agregó lo suficiente.

La demo que sugieren los datos

- Cuenca de Roquette: Aisne, Marne, Somme y Eure-et-Loir como núcleo; Oise como el caso honesto de "mucha área, casi sin ensayos"; Charente-Maritime como contraste.
- Replay a ciegas de 2018 (año malo) y 2023 (año bueno), con el modelo entrenado sin ese año, mostrando cómo cambia la probabilidad entre siembra, floración y floración + 30 d.
- Slider de mix invierno/primavera en la cuenca: el riesgo que el comprador sí controla.
- Aviso en pantalla: 2023 está en el borde de la climatología.

Preguntas que el jurado probablemente haga

- **"La proteína explica solo el 2 % del tonelaje nacional."** Al fabricante le importa la proteína por tonelada que procesa y su propia cuenca; por eso se predice proteína y rendimiento relativo, por cuenca.
- **"¿El clima realmente agrega?"** Mostrar el resultado de la validación dejando un año afuera contra B0 y B1, sea cual sea.
- **"¿Los ensayos representan a las chacras?"** La proteína sí (r 0,86 con los silos); el rendimiento no, por eso es relativo.

Detalle completo, con los 44 plots: research/eda/idea1/ (README.md y un hallazgos.md por carpeta). Los CSV derivados y scripts de exploración se hicieron antes del evento: declararlos como recursos previos o regenerarlos en el evento.